# 용어지식의 통합 및 확장 방안

## - 국립국어원 온용어 플랫폼을 중심으로 -

이 현 주 · 위 진 · 강 미 영 · 곽 용 진*

(국립국어원 학예연구사) · (국립국어원 학예연구관) ·
(국립국어원 학예연구관) · (㈜이르테크 대표)

〈 차 례 〉

1. 서론
2. 용어지식 통합 데이터베이스 구축
3. 용어지식으로 확장
4. 결론
<참고문헌>

〈국문 요약〉

이 연구는 국내의 정부, 기관에서 각자 구축하여 활용하고 있는 모든 용어지식을 한곳에 담아 통합하여 체계화함으로써, 한국형 인공지능 기술 발전에 도움이 될 수 있는 용어지식 플랫폼으로 설계하고 활용하는 방안을 제시한다.

기관별·분야별로 흩어져 있던 용어 자료 등의 데이터베이스를 하나의 체계로 통합하는 방법론으로써 표준적인 분류체계를 적용하고, 각기 다른 용어 자료에 실린 형태와 개념이 같은 용어를 연결하는 과정을 제시하고, 이와 관련한 문제점과 경험적 해결 방안을 논한다. 그리고 용어 데이터에 의미관계와 규칙성을 부여하여 용어지식으로 확장하는 방안과 용어의 통계적 변화추이를 통해 사회 현상을 파악하는 등 용어지식의 활용성을 높이는 방안을 알아본다.

나아가 지식그래프 구축을 통해 인공지능의 한국언어문화 관련 환각현상을 해소하는 등의 활용 방안과 글로벌 지식과도 연계될 수 있는 발전 방향을 찾아본다.

* 제1저자 : 이현주, 교신저자 : 위진, 공동저자 : 강미영, 곽용진.

◎ 주제어: 용어지식, 용어 자료, 지식그래프, 분야 분류, 인공지능, 한국언어문화, 환각현상

## 1. 서론

생성형 인공지능 시대를 맞아 인공지능이 인간을 대체할 것이라는 예측 속에, 세계는 인공지능이 인간의 언어를 잘 이해하고 생성할 수 있도록 하는 노력을 기울이고 있다. 2000년대 초 규칙 기반 모델, 통계 기반 모델에서 더 나아가 규칙과 통계 혼합 모델로 발전했으나, 성능 향상에 한계가 있었다. 그러나 최근 심층학습과 컴퓨터의 계산력 향상으로 인공지능은 방대한 양의 자연어를 학습할 수 있게 되었다. 인공지능은 학습한 자료가 많으면 많을수록 성능이 지속해서 높아진다.

그러나 이러한 발전에도 불구하고 풀어야 할 과제들은 남아있다. 자료가 아무리 많아도 오류가 포함된 자료는 학습 효과를 저하시키고, 인공지능의 고질적 문제점 중 하나로 지적되는 환각현상이라는 사각지대도 존재한다. 또한, 영어 중심의 글로벌 거대기술기업 주도의 인공지능 개발이 가속화되는 가운데 비영어권 나라들은 자국어 기반의 인공지능 개발을 위해 힘을 쏟고 있다. 이런 시대적 상황에서 우리나라도 한국형 인공지능 기술 개발을 위해 많은 노력을 기울이고 있다. 한국어와 한국언어문화를 학습하지 않으면 한국어와 한국언어문화를 잘하는 인공지능 개발은 불가능하다.

용어는 한국어와 한국언어문화의 시작점이라 할 수 있다. 인간은 용어를 통해 지식을 학습하고, 기술을 개발한다. 인간의 언어를 이해하고 처리하는 인공지능에도 마찬가지이다.

용어지식의 통합은 인공지능 발전의 여러 측면에 기여할 수 있다. 통합된 용어지식은 고품질의 지식베이스 구축을 가능하게 하여, 인공지능의 학습 정확도를 높이고 언어 이해력을 향상시킨다. 특히, 뉴로-심볼릭 AI(Neuro-Symbolic AI) 개발에 중요한 역할을 한다. 뉴로-심볼릭 AI는

신경망의 학습 능력과 기호적 추론을 결합하는데, 체계화된 용어지식은 이 과정에서 핵심적인 기호적 지식을 제공한다.(김민호, 2022:59~65) 이를 통해 도메인별 특화된 인공지능 개발, 다국어 처리 능력 강화, 그리고 새로운 개념 생성과 추론이 가능해진다.

이 연구에서는 국립국어원이 국가 차원에서 공공용어를 총괄 관리하기 위해 구축하기 시작한 플랫폼을(강미영, 2020), 인공지능 시대의 활용성을 극대화하기 위한 온용어 플랫폼으로 발전시켜 나가는 방안에 대해 논하고자 한다. 공공용어에서 한 걸음 더 나아가 국내 모든 용어지식을 한곳에 담아 통합하여 체계화함으로써, 한국형 인공지능 기술 발전에 도움이 될 수 있는 용어지식 플랫폼으로 설계하고 활용하는 방안을 제시하고자 한다.

이 연구에서는 우선 기관별·분야별로 흩어져 있던 용어 자료 등의 데이터베이스를 하나의 체계로 통합하는 방법론으로써 표준적인 분류체계를 적용하고, 각기 다른 용어 자료에 실린 형태와 개념이 같은 용어를 연결하는 과정을 제시하고, 이와 관련한 문제점과 경험적 해결 방안을 논한다. 그리고 용어 데이터에 의미관계와 규칙성을 부여하여 용어지식으로 확장하는 방안과 용어의 통계적 변화추이를 통해 사회 현상을 파악하는 등 용어지식의 활용성을 높이는 방안을 알아본다. 나아가 지식그래프 구축을 통해 인공지능 기술 개발 활용 방안과 글로벌 지식과도 연계될 수 있는 발전 방향을 찾아보고자 한다.

## 2. 용어지식 통합 데이터베이스 구축

용어는 인간의 문해력을 결정짓는 중요한 요소이자, 한국어와 한국언어문화를 잘하는 인공지능 기술 개발에도 꼭 필요한 언어자원이다. 그러나 이렇게 귀중한 언어자원인 용어 자료를 모으기 위해서는 여러 난관에 부딪힌다. 기관별로 각자 구축한 자료들이 여기저기 산재되어 있을 뿐만 아니라, 자료의 형태, 제공하는 용어 정보, 저작권 정책 등이 제각각이기 때문이다.

<표 1> 기관별·분야별 용어 자료 목록(일부)

| 용어 자료 | 자료 형태 | 용어 수 | 저작권 정책 |
|---|---|---|---|
| 우리말샘<br>(국립국어원) | 기관 누리집<br>오픈 API | 약 60만 개<br>(전문용어) | CCL |
| 표준용어사전<br>(국가기술표준원) | 기관 누리집 | 122,755 | 기관 협의<br>공공누리 4유형 |
| 정보통신용어사전<br>(한국정보통신기술협회) | 기관 누리집 | 24,055 | 기관 협의<br>공공누리 4유형 |
| 법령정의사전<br>(법제처) | 기관 누리집<br>오픈 API | 44,265 | 기관 협의<br>공공누리 1유형 |
| 한국역사용어시소러스<br>(교육부 국사편찬위원회) | CSV 파일<br>(공공데이터 포털) | 62,409 | 이용 허락 범위<br>제한 없음 |
| 전통지식용어사전<br>(특허청) | XLS 파일<br>(공공데이터 포털) | 56,598 | 이용 허락 범위<br>제한 없음 |
| 국가건설기준용어집<br>(국가건설기준센터) | PDF 파일<br>(공공데이터 포털) | 4,239 | 공공누리 1유형 |

<표 1>에서 보는 바와 같이 용어 자료는 기관 누리집으로 서비스하는 경우, 오픈 API를 통해 제공하는 경우, 공공데이터 포털 등에서 파일로 제공하는 경우, 책으로 출간된 경우 등이 있다. 이러한 자료들을 통합하자면 자료의 유형별로 접근해야 한다. 다행히도 용어 누리집에서 오픈 API를 제공하면 이를 바로 데이터베이스화할 수 있으나, 오픈 API 없이 기관 누리집으로만 서비스하는 경우에는 소관 기관과 직접 협의하여 자료를 제공받아야 한다. 용어가 파일 자료로 제공되는 경우에도 CSV나 XLS 파일과 달리 한글 파일이나 PDF 파일은 데이터베이스로 통합할 수 있도록 구조화하는 작업이 선행되어야 한다.

또한 용어 자료를 통합할 때 무엇보다 필수적으로 확인해야 할 것은 저작권 정책이다. 저작권 유형[1]에 따라 데이터의 변경이나 상업적 이용이 금지되기도 하고, 배포 시 저작권 유형에 제한이 있기도 하므로 통합 데이터를 구축할 때에는 구축 목적, 활용 및 배포 범위 등을 고려하여야

1) 저작권 유형 가운데 공공누리는 공공저작물 자유 이용 허락 표시 제도로, 제1유형~제4유형까지 네 가지 유형이 있다. 유형 및 이용 조건은 아래와 같다.

한다. 또한 이용자들이 자신의 목적에 맞게 편리하게 활용할 수 있도록 제공하려면 제공하는 데이터의 저작권 정책을 명확히 표시해야 한다.

이렇게 용어 데이터를 모은다고 할지라도 체계적이고 일관성 있게 통합하는 방안이 필요하다. 다음 2.1절에서는 다양한 용어 자료 통합 방법론으로 분야별, 기관별로 달리 쓰이는 용어를 통일된 분류체계에 따라 일관성 있게 분류하는 방안과 개념과 형태가 같은 용어를 일치어로 연결하는 방안을 논의한다.

## 2.1. 통일된 분류체계

다양한 용어 데이터를 통합된 데이터베이스로 구축하기 위해서는 국가적 차원에서 안정적으로 관리되면서도, 모든 지식 분류에 적용 가능한 표준적인 분류체계가 필요하다. 국가적으로 관리되고 있는 대표적인 분류체계로는 국가과학기술표준분류체계(과학기술정보통신부), 산업기술분류체계(산업통상자원부), 학술표준분류체계(교육부) 등이 있다. 산업기술분류체계는 학문적인 연구 분야가 포함되어 있지 않아 인문·사회 분야 분류가 불가능하며, 학술표준분류체계는 개정 주기가 정해져 있지 않으며 2009년 이후 큰 폭의 개편이 없었다. 곧, 최신 학문 동향이 반영되지 않을 수 있으며, 안정적인 관리가 어렵다. 반면 국가과학기술표준 분류체계(이하 '과기표준 분류체계')는「과학기술기본법」제27조 및 같은 법 시행령 제41조에 따라 과학기술 관련 정보·인력·연구 개발 사업 등을 효율적으로 관리할 수 있는 분류체계로, 특정 분야에 국한되지 않으며, 5년마다 개정하여 최신 동향을 반영할 수 있는 운영 체계를 갖추고 있다.

이런 이유로, 국립국어원에서는 용어 통합 데이터베이스에 적용할 분

| 제1유형 | 제2유형 | 제3유형 | 제4유형 |
|---|---|---|---|
| 출처표시 | 출처표시+상업적이용금지 | 출처표시+변경금지 | 출처표시+상업적이용금지+변경금지 |

류체계로 '과기표준 분류체계'를 채택하였다.(강미영, 2020:15~19) 2023년에 개정된 과기표준 분류체계는 자연, 생명, 인공물을 포함하는 '과학기술'과 인문사회학, 인간과학과 기술을 포함하는 '인문사회과학'으로 구분되어 있으며, 22개 대분류, 277개 중분류, 2,799개 세부 영역으로 구성되어 있다. 용어 데이터 통합을 위한 분야 분류는 대분류 또는 중분류까지 적용하며, 세부 영역은 대분류, 중분류를 정하는 데 참고하는 방식으로 진행한다.

<표 2> 과기표준 분류체계의 구성

| 연구 분야 | | 대분류 | 중분류 |
|---|---|---|---|
| 과학기술 | 자연 | 수학 | 대수학, 해석학… |
| | | 물리학 | 입자/장물리, 통계 물리… |
| | | 화학 | 물리화학, 유기화학… |
| | | 지구과학 | 지질과학, 지구물리학… |
| | 생명 | 생명과학 | 분자세포생물학, 유전학·유전체학… |
| | | 농림수산식품 | 식량작물과학, 원예특용작물과학… |
| | | 보건의료 | 의생명과학, 임상의학… |
| | 인공물 | 기계 | 측정표준·시험평가기술, 생산기반기술… |
| | | 재료 | 금속재료, 세라믹재료… |
| | | 화공 | 화학공정, 나노화학공정기술… |
| | | 전기/전자 | 광응용기기, 반도체장비… |
| | | 정보/통신 | 정보이론, 소프트웨어… |
| | | 에너지/자원 | 온실가스처리, 자원탐사·개발·활용… |
| | | 원자력 | 원자로노심기술, 원자로계통심기기기술… |
| | | 환경 | 대기질관리, 물관리… |
| | | 건설/교통 | 국토정책·계획, 국토공간개발기술… |
| 인문사회과학 | 인문사회학 | 인문학 | 역사학, 철학… |
| | | 사회과학 | 정치외교학, 경제학… |
| | | 문화예술체육학 | 음악학, 미술… |
| | 인간과학과기술 | 뇌과학 | 뇌신경생물, 뇌인지… |
| | | 인지/감성과학 | 인지과학, 감성과학… |
| | | 과학기술과 인문사회 | 과학기술사, 과학기술철학… |
| 합 계 | | 22 | 277 |

수많은 용어를 효율적으로 분류하기 위해 나름의 분야 정보를 가지고 있는 자료와 분야 정보가 전혀 없는 자료로 나누어 분류 작업을 진행할 필요가 있다. 전자의 경우에는 자료집 자체 분야 정보 또는 그에 준하는 정보를 바탕으로 과기표준 분류체계와 매핑하여 분야 정보를 주고, 후자의 경우에는 과기표준 분류체계에 따라 용어별로 하나하나 분류한다.

자체 분야 정보를 갖춘 자료집으로는 국립국어원의 ≪우리말샘≫ 전문용어, 한국정보통신기술협회의 ≪정보통신용어사전≫, 한국전력공사의 ≪전력용어집≫, 학술단체총연합회의 ≪학술용어목록≫, 국가기술표준원의 ≪표준용어사전≫ 등이 있다.

자체 분야 정보를 갖춘 자료 중 가장 복잡한 체계를 가진 자료가 국립국어원의 ≪우리말샘≫ 전문용어이다. ≪우리말샘≫ 전문용어는 67개 분야로 분류되어 있는데, ≪우리말샘≫의 분야 분류 해설과 과기표준 분류체계의 해설서를 참고하여 다음과 같이 매핑할 수 있다.

<표 3> 우리말샘-과기표준 분야 매핑 결과

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 교육 | 사회과학 | 교육학 |
| 문학 | 인문학 | 문학 |
| 민속 | 인문학 | 역사학 |
| 언어 | 인문학 | 언어학 |
| 역사 | 인문학 | 역사학 |
| 철학 | 인문학 | 철학 |
| 인문일반 | 인문학 | 사전학, 통번역학, 기타 인문학 |
| | 사회과학 | 문헌정보학, 인류학… |

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 임업 | 농림수산식품 | 산림자원학, 조경학 … |
| 산업일반 | 과학기술과 인문사회 | 안전사회/재난관리 |
| | 화공… | 화학공정안전기술 … |
| 수의 | 농림수산식품 | 수의과학 |
| 식품 | 농림수산식품 | 식품과학, 식품영양과학… |
| 약학 | 보건의료 | 신약·의약품개발, 의약품 안전관리… |
| 의학 | 보건의료 | 의생명과학, 임상의학… |
| 한의 | 보건의료 | 한의과학 |

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 경영 | 사회과학 | 경영학 |
| 경제 | 사회과학 | 경제학 |
| 군사 | 사회과학 | 군사학 |
| 매체 | 사회과학 | 신문방송학 |
| | 정보/통신 | 디지털방송·콘텐츠 |
| 법률 | 사회과학 | 법학 |
| 복지 | 사회과학 | 사회복지학 |
| 심리 | 사회과학 | 심리과학 |
| 정치 | 사회과학 | 정치외교학 |
| 행정 | 사회과학 | 행정학・정책학 |
| 사회 일반 | 사회과학 | 회계학, 인류학… |
| 동물 | 농림수산식품 | 동물자원과학 |
| 물리 | 물리학 | 입자/장물리, 통계물리… |
| 생명 | 생명과학 | 분자세포생물학, 유전학·유전체학… |
| 수학 | 수학 | 대수학, 해석학… |
| 식물 | 농림수산식품 | 농생물학 |
| 지구 | 지구과학 | 대기과학, 자연재해분석/예측… |
| 지리 | 사회과학 | 지리학 |
| 천문 | 지구과학 | 천문학 |
| 천연자원 | 에너지/자원 | 온실가스처리, 자원탐사/개발/활용… |

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 보건일반 | 보건의료 | 간호과학, 의료기기… |
| 건설 | 건설/교통 | 국토정책/계획, 국토공간개발기술… |
| 교통 | 건설/교통 | 도로교통기술, 철도교통기술… |
| 기계 | 기계 | 측정표준/시험, 가기술, 생산기반기술… |
| 재료 | 재료 | 금속재료, 세라믹재료… |
| 전기·전자 | 전기/전자 | 광응용기기, 반도체장비… |
| 정보·통신 | 정보/통신 | 정보이론, 소프트웨어… |
| 공학 일반 | 화공 | 화학공정 |
| | 원자력… | 원자력 안전기술… |
| 체육 | 문화예술체육학 | 체육 |
| 연기 | 문화예술체육학 | 연극 |
| 영상 | 문화예술체육학 | 영화 |
| | 전기/전자… | 영상/음향기기… |
| 무용 | 문화예술체육학 | 무용 |
| 음악 | 문화예술체육학 | 음악학 |
| 미술 | 문화예술체육학 | 미술 |
| 복식 | 화공 | 섬유제품 |
| | 문화예술체육학 | 의상 |
| 공예 | 문화예술체육학 | 미술 |

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 해양 | 지구과학 | 지질과학, 지구물리학… |
| 화학 | 화학 | 물리화학, 유기화학… |
| 환경 | 환경 | 대기질관리, 물관리… |
| 자연일반 | 생명과학 | 분류/생태/환경 생물학 |
| | 농림수산식품… | 농업환경생태… |
| 공업 | 화공 | 정밀화학… |
| | 원자력… | 원자력계측/제어기술… |
| 광업 | 지구과학 | 지질과학 |
| 농업 | 농림수산식품 | 농생물학, 농화학… |
| 서비스업 | 사회과학 | 관광학 |
| 수산업 | 농림수산식품 | 수산양식, 수산자원/어장환경… |

| 우리말샘 | 과기표준 | |
|---|---|---|
| | 대분류 | 중분류 |
| 예체능일반 | 문화예술체육학 | 사진, 미용… |
| 가톨릭 | 인문학 | 가톨릭 신학 |
| 기독교 | 인문학 | 기독교 신학 |
| 불교 | 인문학 | 불교학 |
| 종교일반 | 인문학 | 종교학, 유교학 |
| 인명 | - | - |
| 지명 | 사회과학 | 지리학 |
| 책명 | 인문학 | 문학, 역사학… |
| | 사회과학… | 법학, 지리학… |
| 고유명일반 | 사회과학 | 인류학, 역사학… |
| | 건설/교통… | 도로교통기술… |

≪우리말샘≫의 분야 가운데 과기표준 분류체계의 대분류, 중분류까지 일 대 일로 매핑이 가능한 분야는 교육, 경제 등 총 30개이며, 대분류까지 매핑이 가능한 분야는 사회일반, 물리 등 총 24개이다. ≪우리말샘≫의 분야 67개인 것에 비해 과기표준의 중분류는 277개나 되므로 일 대 다로 매핑되는 경우가 13건으로 약 20%를 차지한다. 이러한 경우에는 용어별로 각각의 정보를 분석하여 분야 분류 작업을 진행해야 한다.

국가기술표준원의 ≪표준용어사전≫에는 산업 표준 분야가 명시되어 있으나 대분야까지만 정보가 있어 과기표준 분류체계와 매핑하기에는 정보가 부족하다. 따라서 용어의 출처로 제시된 표준명(국가표준 문서 제목)을 기준으로 하면 더 정확한 과기표준 분류와 연결할 수 있다. 예를

들어 표준 용어 사전의 '물류 거점', '물류 모듈' 등의 분야는 '기본'인데 이를 과기표준 분류체계에 매핑하기는 어렵다. 그러나 '물류 거점', '물류 모듈' 등의 출처(표준명)는 '물류 용어'이므로, 과기표준 분류체계의 대분류 '건설/교통', 중분류 '물류기술'로 연결할 수 있다.

<표 4> 기표원 표준용어사전-과기표준 분류체계 연결 예시

| 표준용어사전 | | 과기표준 | |
|---|---|---|---|
| 산업 표준 분야 | 표준명 | 대분류 | 중분류 |
| 기본 | 물류 용어 | 건설/교통 | 물류기술 |
| 기본 | 원자력발전소<br>-유지보수 능력-용어 | 원자력 | 원전 건설/운영 기술 |
| 서비스 | 국외 여행 서비스-프로세스 | 사회과학 | 관광학 |
| 서비스 | 노인요양시설 서비스<br>-제1부 프로세스 | 사회과학 | 사회복지학 |
| 정보 | 번역 프로젝트 - 일반 지침 | 언어 | 통역번역 |
| 정보 | 보건의료정보<br>—용어 체계를 위한 어휘 | 보건의료 | 의료정보/시스템 |

다음으로 용어 자료에 분야 정보가 아예 없거나 체계 대 체계 매핑으로 분야 정보를 확정하지 못한 경우에는 용어별로 과기표준 분류체계 해설서를 참고하여, 분류해야 한다. 이를 위한 기본 원칙은 용어 개념에 맞는 분야로 분류하는 것이다. 용어의 정의문에 기술되어 있는 유개념[2)]에 해당하는 과기표준 분류체계의 분야로 분류한다.

2) 유개념: 어떤 개념의 외연(外延)이 다른 개념의 외연보다 크고 그것을 포괄할 경우, 전자를 후자에 대하여 이르는 말. 예를 들면, 소나무·매화나무 따위의 종개념에 대하여 식물이 이에 해당한다.(출처: 국립국어원 ≪표준국어대사전≫)

<표 5> 유개념을 기준으로 한 분야 분류 예시

| 용어 | 정의문 | 유개념 |
|---|---|---|
| 확성기 | 전기 신호를 음향 신호로 바꾸어 주는 **음향 기기**. (이하 생략) ≪정보통신용어사전(한국정보통신기술협회)≫ | 음향 기기 |
| 사료^작물^수확^기계 | 사료 작물을 수확하거나 또는 사료 작물을 짧고 평행한 길이로 절단하여 컨테이너 또는 분리된 차량에 적재하는 데 사용하는 **농업 기계**. ≪표준용어사전(국가기술표준원)≫ | 농업 기계 |

→

| 과기표준 분류 | |
|---|---|
| 대분류 | 중분류 |
| 전기/전자 | 영상/음향 기기 |
| 농림수산 식품 | 농업·식품 기계·설비 |

그러나 용어 자료에 따라 유개념이 두 개인 정의문도 있는데, 이 경우에는 두 유개념을 포괄하는 분야로 분류할 수 있다.

<표 6> 유개념이 두 개인 경우 분야 분류 예시

| 용어 | 정의문 | 유개념 |
|---|---|---|
| 가로^쐐기 | 다른 재료에 끼워 넣어서 이것을 고정하기 위하여 사용하는 쐐기형의 **강**. 또는 **목재 조각**. ≪우리말샘(국립국어원)≫ | 강, 목재 조각 |
| 스캣 | 재즈 따위에서, 가사 대신 아무 뜻이 없는 후렴을 넣어서 부르는 **창법**, 또는 그런 **노래**. ≪우리말샘(국립국어원)≫ | 창법, 노래 |

→

| 과기표준 분류 | |
|---|---|
| 대분류 | 중분류 |
| 건설/교통 | 건설시공/재료 |
| 문화예술체육학 | 음악 |

한편 한국어 특성상 수식어가 피수식어에 선행하므로 중심 개념이 용어의 오른쪽에 놓이는 경우가 많으므로, 이 특성을 고려하여 분류해야 한다.

<표 7> 후행어를 기준으로 한 분야 분류 예시

| 용어 | 정의문 | 중심 개념 | | 과기표준 분류 | |
|---|---|---|---|---|---|
| | | | | 대분류 | 중분류 |
| 법교육 | 법교육지원법상의 용어로서 청소년 및 일반 국민에게 법에 대한 지식과 기능…법과 관련된 일체의 교육을 말한다. ≪법령용어사례집(한국법제연구원)≫ | 교육 | → | 사회과학 | 교육학 |
| 교육법 | 경제 활동에서 생기는 모순과 폐해를 정책적으로 조정하고 통제하기 위한 법. ≪우리말샘(국립국어원)≫ | 법 | | 사회과학 | 법학 |

그러나 예외적인 경우도 있을 수 있다. <표 8>과 같이 '~협약', '~협정'과 같은 경우에 후행어를 기준으로 분류한다면 대분류 '사회과학' 중분류 '정치외교학'으로 분류할 수 있다. 그러나 '국제^환경^협약', '관세^및^무역에^관한^일반^협정'은 어떤 목적을 가지고 어느 분야에서 이루어지는 협약 또는 협정인지가 중요하므로 선행어를 중심 개념으로 분류할 수 있을 것이다.

<표 8> 선행어를 기준으로 한 분야 분류 예시

| 용어 | 정의문 | 중심 개념 | | 과기표준 분류 | |
|---|---|---|---|---|---|
| | | | | 대분류 | 중분류 |
| 국제^환경^협약 | 환경을 보호하기 위하여 체결되는 양자 간 다자간 국제 협약. (이하 생략) ≪우리말샘(국립국어원)≫ | 환경 | → | 환경 | 환경예측/감시/평가 |
| 관세^및^무역에^관한^일반^협정 | 관세와 통상의 불합리성을 제거하여 물자 교류의 촉진과 고용 수준의 향상을 목적으로 한 국제적 협정. (이하 생략) ≪산업 자원 용어·약어 해설집(산업통상자원부)≫ | 무역 | | 사회과학 | 무역학 |

위와 같은 기준을 적용하여, 현재 시범 운영 중인 '온용어 플랫폼(kli.korean.go.kr/term)'에서는 30개 기관에서 만든 40개 용어 자료의 103만여 용어를 과기표준 분류체계에 따라 데이터베이스로 통합하고 있다.

### 2.2. 일치어 연결

이 절에서는 기관별·분야별 용어 자료를 통합하기 위한 또 하나의 방법론으로 일치어 연결에 대해 논한다. 여러 기관에서 만들어진 다양한 용어 자료를 모으다 보면 형태와 개념이 같은 용어들이 있을 수밖에 없다. 사용성이 높은 용어들은 여러 분야의 자료집에서 확인된다. 예를 들어, '인공^지능'은 국가기술표준원의 ≪표준용어사전≫, 한국정보통신기술협회의 ≪정보통신용어사전≫, 국립국어원 ≪우리말샘≫, 특허청 ≪지식재산권용어사전≫, 국토교통부 ≪항공용어사전≫ 등에 실려 있다. 정의문의 표현은 조금씩 다르지만 같은 형태의 같은 개념을 가진 용어이다. 이 논문에서는 이러한 용어들을 '일치어'로 명명하고, 각기 다른 자료집에 있는 용어 정보를 한눈에 볼 수 있도록 통합하는 방법론으로 일치어 연결 방법을 제시한다.

<표 9>는 여러 용어 자료에 실려 있는 '인공지능'으로, 일치어로 연결할 수 있는 예시이다. 일치어로 연결해서 보여 주면, 다양한 개념 정의를 확인할 수 있으며 용어 자료의 특성에 따라 제공되는 부가적인 정보도 한번에 확인할 수 있다. 한국정보통신기술협회 ≪정보통신용어사전≫의 '인공지능' 정의문에는 용어가 처음 사용된 때부터 현재까지 어떠한 기술 발전이 이루어졌는지를 설명한다. 특허청 ≪지식재산권용어사전≫의 '인공지능' 정의문에는 지식 재산권과 관련하여 어떤 문제가 나타나고 있는지를 설명한다. 이 용어들을 일치어로 묶어 보여 줌으로 인해서 각 기관의 자료를 일일이 검색하여 찾지 않아도 되니 편리하고, 다양하고 풍부한 정보도 얻을 수 있다. 이러한 통합 제시 방법은 분야 간 소통을 원활히 하여 전문용어 표준화의 밑거름이 될 수 있다.

<표 9> 용어 자료별 '인공^지능'의 정의

| 용어 자료 | 정의문 |
|---|---|
| 표준용어사전<br>(국가기술표준원) | 추론이나 학습과 같이 인간의 지능과 관련된 일반적인 기능들을 수행하기 위한 모델이나 시스템을 다루는 전산학의 한 분야로서, 여러 학문과 관계있는 분야. |
| 정보통신용어사전<br>(한국정보통신기술협회) | 컴퓨터로 구현한 지능 또는 이와 관련한 전산학의 연구 분야. 인공지능은 사람 또는 동물의 지능이 컴퓨터로 모사될 정도로 세밀하고 정확하게 표현될 수 있다는 생각에 기반을 둔다. … 인공지능이라는 용어는 1956년 미국 다트머스 대학(Dartmouth College)에서 열린 워크숍 제안서에서 존 매카시(John McCarthy)가 처음 공식적으로 사용하였다.(이하 생략) |
| 우리말샘<br>(국립국어원) | 인간의 지능이 가지는 학습, 추리, 적응, 논증 따위의 기능을 갖춘 컴퓨터 시스템. 전문가 시스템, 자연 언어의 이해, 음성 번역, 로봇 공학, 인공 시각, 문제 해결, 학습과 지식 획득, 인지 과학 따위에 응용한다. |
| 지식재산권용어사전<br>(특허청) | 컴퓨터 공학의 한 분야로 인간의 지각, 추론, 학습 능력 등을 컴퓨터 기술을 이용하여 구현함으로써 문제 해결을 할 수 있는 기술. … 지식 재산권과 관련하여서는 인공지능 로봇이 발명자 또는 창작자가 될 수 있는지, 인공지능 로봇이 만들어낸 창작물의 권리를 누구에게 귀속시킬 것인지 등의 문제가 대두되고 있다. |
| 항공용어사전<br>(국토교통부) | 인간의 학습 능력과 추론 능력, 지각 능력, 자연 언어 이해 능력 등을 컴퓨터 프로그램으로 실현한 기술. |

그러나 각각의 용어 자료를 대상으로 형태와 개념이 같은 일치어를 선별하기는 쉽지 않다. 같은 형태는 눈으로 바로 확인하거나 자동으로 추출할 수 있지만, 개념이 같은지를 판단하는 작업은 쉽지 않다. 대부분의 용어 자료는 한 용어 자료 안에 형태와 개념이 같은 용어를 싣지 않으므로 이종의 자료에 실려 있는 용어들을 대상으로 일치어 검토가 이루어지지만 국가기술표준원의 ≪표준용어사전≫이나 법제처의 ≪법령정의사전≫ 등에는 형태와 개념이 같은 용어가 다수 실려 있다.[3] 이런 경우에

3) 국가기술표준원의 ≪표준 용어 사전≫은 표준 규격서에 실려 있는 용어 정의를

는 한 용어 자료 내의 용어들을 대상으로도 일치어 검토가 필요하다.

<표 10> 용어 자료 내 일치어 예시

| 용어 자료 | 용어 | 정의문 | 출처 |
|---|---|---|---|
| 표준용어사전 (국가기술표준원) | 인공지능 | 추론이나 학습과 같이 인간의 지능과 관련된 일반적인 기능들을 수행하기 위한 모델이나 시스템을 다루는 전산학의 한 분야로서, 여러 학문과 관계있는 분야 | 정보기술 - 용어 - 제28부: 인공지능 - 기본 개념 및 전문가 시스템 (KSX0001-28) |
| | | 보통 추리나 학습 같은 인간의 지능과 결합된 기능을 수행하는 기계의 능력 | 인쇄 회로 기판 설계, 제조 및 조립 –용어와 정의 (KSCIEC60194) |
| | | 인식 능력, 학습 능력, 추상적 사고 능력, 환경 적응 능력 등을 인공적으로 실현한 것 | 로봇 – 용어 (KSBISO8373) |
| 법령정의사전 (법제처) | 가스 누설 경보기 | 가스가 새는 것을 탐지하여 관계자나 이용자에게 경보하여 주는 것을 말한다. (이하 생략) | 중계기의 형식승인 및 제품검사의 기술기준(소방청고시 2024-11호) |
| | | 가스시설이 설치된 장소에서 액화석유가스(LPG), 액화천연가스(LNG), 일산화탄소 또는 기타 가스(이소부탄, 메탄, 수소)를 탐지하여 경보하는 것을 말한다. (이하 생략) | 가스누설경보기의 형식승인 및 제품검사의 기술기준(소방청고시 제2023-8호) |
| | | 건설현장에서 발생하는 가연성 가스를 탐지하여 경보하는 장치를 말한다. | 건설현장의 화재안전성능기준(소방청고시 제2023-23호) |

또한 한 자료 안에 형태는 같지만 개념이 다른 용어가 실려 있는 경우도 있다. 예를 들어 ≪우리말샘≫은 의미 단위로 용어가 실려 있으므로

모아 놓은 자료이므로 출처가 다른 표준 규격서에 실린 형태와 개념이 같은 용어가 실려 있으며 법제처의 ≪법령 정의 사전≫도 마찬가지로 서로 다른 법령에 실려 있는 형태와 개념이 같은 용어가 다수 실려 있다.

형태가 같은 용어가 있더라도 이는 의미가 다른 동형이의어거나 다의어이다. 예를 들어 ≪우리말샘≫에서 '차폐'는 아래와 같이 전기/전자 용어와 군사 용어로 정의되어 있다.[4)]

<표 11> 다의어와 일치어 예시

| 용어 | 용어 자료 | 정의문 |
|---|---|---|
| 차폐 1 | 우리말샘<br>(국립국어원) | 일정한 공간이 외부의 전기, 자기 따위의 영향을 받지 않도록 함. 또는 그런 일. |
| 차폐 2 | 우리말샘<br>(국립국어원) | 구릉, 능선, 둑 따위의 자연 장애물로 적의 사격이나 관측으로부터 주요 시설을 지켜서 보호함. 또는 그런 일. |
| 차폐 3 | 발전용어집<br>(한국서부발전) | 어떤 공간을 주변에 존재하는 전계와 자계로 부터 차단하는 것. |
| 차폐 4 | 국방과학기술용어사전<br>(국방기술진흥연구소) | 언덕, 경사로, 비탈과 같은 장애물에 의해 적의 화기와 감시로부터 보호되는 일. |

위와 같은 경우 전기/전자 용어로 쓰인 ≪우리말샘≫의 '차폐 1'과 ≪발전용어집≫의 '차폐 3'을 일치어로 연결하고, 군사 용어로 쓰인 ≪우리말샘≫의 '차폐 2'와 ≪국방과학기술용어사전≫의 '차폐 4'를 일치어로 연결하는 것이다.

또한 용어 자료에 따라 개념을 일반적으로 기술한 경우와 세분화하여 기술한 경우가 있다. 아래 '접착제 1~3'과 같이 두 가지 물체(표면)를 붙이는 데 사용하는 물질로 일반적인 풀이한 경우가 있는가 하면 '접착제 4~5'와 같이 특정 분야에서만 사용하는 접착제로 세분화하여 풀이한 경우가 있다. 이러한 경우 원자료의 개념 정의를 존중하여 '접착제 1~3'만 일치어로 연결한다.

4) ≪우리말샘≫에 '차폐'는 일반어로서 의미도 등재되어 있어 세 가지 의미를 지닌 다의어이나, 본고에서는 분야별 용어를 대상으로 논의를 진행하고 있으므로 일반어로서의 의미는 논외로 한다.

<표 12> 개념의 구체성과 일치어 예시

| 용어 | 정의문 | 출처 |
|---|---|---|
| 접착제 1 | 두 표면 사이를 붙이기 위하여 사용되는 화학 물질. 표면에 젖은 상태로 입히고 굳으면 두 표면을 견고하게 부착한다. | 항공용어사전(국토교통부) |
| 접착제 2 | 두 개체를 붙이기 위하여 사용하는 물질. | 환경 및 무역 관련 용어 정의 정보(한국환경산업기술원) |
| 접착제 3 | 재료 표면을 서로 부착시킬 수 있는 물질. | 표준용어사전(국가기술표준원) |
| 접착제 4 | 시멘트 콘크리트 및 아스팔트 콘크리트 바닥 위에 시트 및 패드를 접착하기 위해 사용하는 접착제를 말한다. | 표준용어사전(국가기술표준원) |
| 접착제 5 | 필름대 제조 시 사용되는 접착제로 천연, 합성 또는 이들을 조합한다. | 표준용어사전(국가기술표준원) |

마지막으로 개념 정의는 유사하나 층위가 다른 경우도 있다. ‘디지털 화폐’의 경우 한국정보통신기술협회의 ≪정보통신용어사전≫에서는 ‘전자 화폐’, ‘가상 화폐’, ‘암호화 화폐’를 포괄하는 상위 개념으로 정의하였으나 ≪우리말샘≫에서는 ‘디지털 화폐’와 ‘전자 화폐’를 동의 관계로 정의하였다. 개념의 층위가 다르므로 ≪정보통신용어사전≫의 ‘디지털 화폐’와 ≪우리말샘≫의 ‘디지털 화폐’는 일치어로 연결하지 않는다.

<표 13> 개념의 층위와 일치어 예시

| 용어 자료 | 정의문 | 관련 용어 |
|---|---|---|
| 정보통신용어사전(한국정보통신기술협회) | 디지털 방식으로 사용하는 형태의 화폐. 디지털 화폐는 컴퓨터에 보관하여 사용하거나 네트워크 상에서 사용하기도 하는데, 아이시(IC)카드에 금전적 가치를 디지털화하고 암호화된 형태로 저장하여 휴대 사용이 가능한 화폐를 말한다. 따라서 디지털 화폐는 전자화폐, 가상화폐, 암호화폐 등을 모두 포함한다. (이하 생략) | 하위어: 전자 화폐, 가상 화폐, 암호화 화폐 |
| 우리말샘(국립국어원) | 실제의 물리적인 화폐는 아니지만 컴퓨터 네트워크를 통하여 같은 기능을 하는 화폐. | 동의어: 전자 화폐, 사이버 캐시, 전자돈 |

## 3. 용어지식으로 확장

용어 데이터에서 용어지식으로의 확장은 인공지능이 한국어와 한국언어문화를 학습하고, 이에 관련한 문제를 해결하거나 추론하는 자료로서 활용성을 높이는 일이 될 것이다. 용어 데이터를 용어지식으로 확장하는 방법으로, 용어 데이터가 지니는 여러 개념들을 의미관계에 따라 연결하여 용어지식으로 체계화하고 개념화가 가능하다. 또한 용어의 사용 빈도를 통해 사회적 현상을 해석할 수 있다.

이 장에서는 용어지식을 확장하는 방법론으로 용어 정보를 입체적으로 제시하여 용어 의미 이해를 돕는 용어 개념도와 한국언어문화 용어를 중심으로 지식그래프로 확장하는 방법론에 대해 논한다.

### 3.1. 용어 개념도와 용어 사용 추이

용어의 의미는 그 용어가 가지는 개념들의 총합으로 이해되기도 하며, 유개념과 종개념으로 정의되기도 하며, 상하·동의·반의 등의 관계를 맺는 의미관계를 통해 규정되기도 한다. 특정 용어가 가질 수 있는 의미 정보들로는 전문 분야, 원어와 대역어, 정의문, 일치어, 동의어, 다듬은 말, 다듬을 말, 표준 전문 용어, 표준화 대상 용어, 참고어 등을 상정할 수 있다. 위에서 일치어로 연결한 ‘인공지능’을 예로 들어, 개념과 의미관계를 살펴보면 다음과 같다.

<표 14> ‘인공^지능’의 의미 정보

| 의미관계 | 의미 정보 |
|---|---|
| 분야 | <과기표준> 정보/통신 > 정보이론 |
| 원어 | 人工知能 |
| 대역어 | 없음 |
| 정의문 | 인간의 지능이 가지는 학습, 추리, 적응, 논증 따위의 기능을 갖춘 컴퓨터 |

| | |
|---|---|
| | 시스템. 전문가 시스템, 자연 언어의 이해, 음성 번역, 로봇 공학, 인공 시각, 문제 해결, 학습과 지식 획득, 인지 과학 따위에 응용한다. |
| 일치어 | 인공^지능 ≪표준용어사전(국가기술표준원)≫, 인공^지능 ≪법령정비용어집(법제처)≫, 인공^지능 ≪정보통신용어사전(한국정보통신기술협회)≫, 인공^지능 ≪국방통합용어사전(방위사업청)≫, 인공^지능 ≪항공 용어사전(국토교통부)≫, 인공^지능 ≪발전 용어집(한국서부발전)≫, 인공^지능 ≪산업자원용어 약어 해설집(산업통상자원부)≫, 인공^지능 ≪지식재산권용어사전(특허청)≫, 인공^지능 ≪21세기 세종 계획 전문용어(국립국어원)≫ |
| 동의어 | 에이아이 |
| 다듬을 말<br>(순화 대상어) | 에이아이 |

그런데 인공지능이 정작 '인공지능'의 개념을 이해하고 추론하기 위해서는, <표 14>에서 제시한 낱낱의 의미 정보들의 연결이 필요하다. 그래서 용어의 표제어를 중심으로 각각의 의미 정보들을 연결하여 시각화한 '용어 개념도'를 고안하였다.

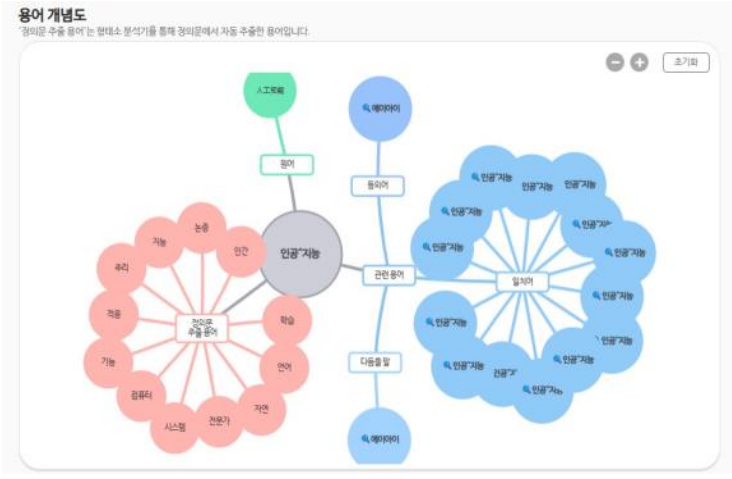


[그림 1] '인공지능'의 용어 개념도

용어 개념도에 담을 수 있는 정보로는 표제어를 중심으로 원어와 대역어, 정의문 추출 용어, 일치어, 동의어, 다듬은 말, 표준 전문 용어, 참고어 등이 있다.

원어와 대역어 정보는 표제어를 다른 언어로 통번역할 때 필요한 번역 정보이고, 정의문 추출 용어는 표제어 개념을 구성하는 주된 의미 속성들이다. 정의문에서 추출한 용어는 형태소 분석을 통해 정의문에서 자동 추출한 개념들로, 개념을 추출할 때에 정의문이 지니는 유개념과 종개념을 고려한다. 예를 들어 '인공지능'의 정의문에서는 '인간, 능력, 구현, 문제, 추론, 학습, 기술, 지각, 컴퓨터, 분야, 공학'을 주요 의미 속성으로 추출할 수 있다.

또 다른 용어 정보인 공공언어 개선으로 마련되는 다듬을 말, 다듬을 대상이 된 용어도 제시한다. 곧, 외래어인 '에이아이'를 '인공지능'으로 순화한 정보를 제공하고, 공공적 영역에서 '에이아이'보다는 '인공지능'을 사용하라는 내용을 함의하고 있다. 그리고 동의어와 '2.2 일치어 연결'에서 제시한 일치어 정보가 있는 입체적 개념도에 연결될 수 있는데, 이러한 일치어 정보는 전문 분야별 용어의 사용역을 종합적으로 보여 준다.

한편, 용어는 사용 빈도 등의 통계 정보를 통해 사회적 의미를 획득하기도 한다. 용어 데이터에 통계 정보를 연계하면, 용어지식은 사회적 현상과 의미를 해석하는 자료로 활용될 수 있다. 사회적 공신력이 있으면서도 통계 정보 수집이 용이한 데이터로는 한국언론진흥재단의 '빅카인즈'[5] 정보가 있다. 특정 용어가 빅카인즈의 언론 기사에 10년 또는 일정 기간 동안 나타난 빈도를 분석하여 그래프로 표현한 '용어 사용 추이'를 작성한다면, 특정 용어를 통한 당시의 사회 현상 분석이 가능하다. 특히 특정 용어와 관련된 용어를 비교하여 볼 수 있는 구조로 시각화한다면,

5) 빅카인즈는 한국언론진흥재단에서 운영 중인 뉴스 빅데이터 분석 서비스이다. 서울, 경기 등 7개 지역 104개 언론사(종합 일간지, 경제지, 지역 일간지, 방송사 등) 기사 데이터베이스에 빅데이터 분석 기술을 접목하여 뉴스 분석 정보를 제공한다.

두 용어 간의 사회적 관계도 해석할 수 있을 것이다.

‘가상 현실’과 ‘브이아르(VR)’의 10년 동안의 용어 사용 추이를 비교하면, 다음과 같다.

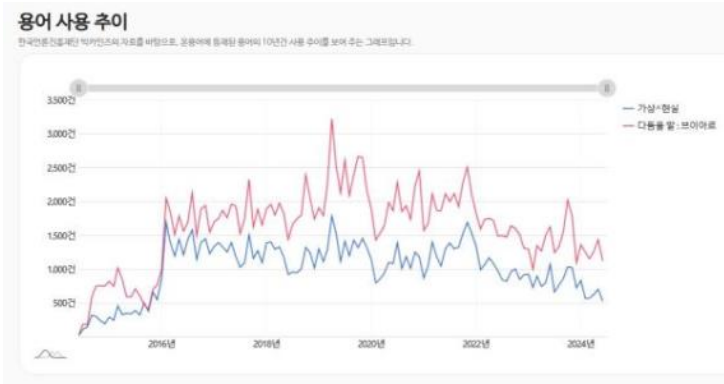


[그림 2] ‘가상 현실’과 ‘브이아르’ 용어 사용 추이

2014년 6월에 ‘가상 현실’은 18회, ‘브이아르(VR)’은 28회 사용되었으며, 10년 뒤인 2024년 6월에는 ‘가상 현실’이 530회, ‘브이아르(VR)’가 1,127회 사용되었다. 특히, 사용 빈도가 가장 높은 시기는 2019년 4월로 ‘가상 현실’이 1,787회, ‘브이아르(VR)’가 3,229회 언론기사에 나타났다.

[그림 2]의 사용 추이는 ‘가상 현실’, ‘브이아르(VR)’ 기술이 2019년 4월에 사회적 이슈로 주목받는 계기가 있었고, 현재에는 관심도가 떨어지는 사실을 보여 준다. 그리고 ‘가상 현실’, ‘브이아르(VR)’가 다듬은 말(순화어)과 다듬을 말(순화 대상어)인 점을 생각하면, 현재까지도 사회에서는 다듬을 말에 대한 사용 빈도 및 선호도가 높은 것으로 해석될 수 있다.

### 3.2. 한국언어문화 지식그래프

최근 주목받는 생성형 인공지능의 고질적인 문제인 환각현상을 방지

하고, 한국형 인공지능을 개발하는 데 필수적인 용어지식으로 한국언어문화 지식그래프를 구축하는 방법을 고려할 수 있다.

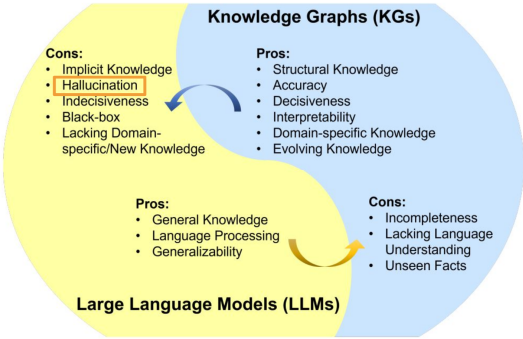


[그림 3] 생성 언어 모델(Large Language Model)과 지식 그래프 장단점 비교 (Pan et al., 2023)

지식그래프는 구글 발표[6]로 대중적인 용어가 되었으나 온톨로지와 함께 지식 표현과 추론 분야에서 지속적으로 연구되어 왔다. 최근에는 생성형 인공지능인 초거대언어모델(Large Language Mode, LLM, 이하 LLM)의 문제점을 보완하기 위한 대책으로 다시 주목받고 있다. LLM의 문제점을 보완하기 위한 대책으로 함께 주목받고 있는 검색증강생성(Retrieval-Augmented Generation, RAG)[7]의 일환인 'VectorDB'나 LLM의 확률 기반 추론과 달리 결정론적(Deterministic)인 지식베이스는 LLM의 환각현상을 방지하는 데 특히 효용성이 높다.

특히 한국형 인공지능 기술 개발 관점에서는 국가의 언어, 문화, 역사 등 국가·민족의 정체성과 관련된 지식이 중요한 역할을 하게 된다.[8] 최

6) A. Singhal. Introducing the Knowledge Graph: Things,not Strings, May 2012. https://googleblog.blogspot.co.at/2012/05/introducing-knowledge-graph-things-not.html [August, 2016].

7) 'RAG'는 LLM이 출력을 최적화하여 답변을 생성하기 전에, 학습에 사용된 데이터와는 다른 외부의 신뢰할 수 있는 지식베이스를 참조하도록 하는 방식이다.

8) 예를 들어 "독도에 대해 설명하시오."에 대해 우리나라 사람이 기대하는 답변과

근 한국형 인공지능 기술 개발에서 대두되고 있는 한국언어문화 자료 공백을 해소할 수 있는 의미 있는 자료가 될 것이기 때문이다.

현재 국어원에서 설계 중인 한국언어문화 지식그래프는 한국학중앙연구원의 『한국민족문화대백과사전』에서 상위 조회수를 기록한 표제어 중 한국의 언어문화와 밀접한 관련이 있다고 판단되는 분야의 어휘 5,000여 개의 표제항 대상으로 한다. 한국언어문화 지식그래프의 표현은 표제항을 중심어로 삼고, 표제항을 기술하는 데 필요한 용어를 관계어로 정의하여 중심어(출발어)와 관계어의 관계(메타관계)를 서술어로 삼아 그래프 표현 방식인 '트리플(triple)'[9]로 구성했다. 이는 한국언어문화 지식그래프가 과학기술과 같은 보편적인 지식과 다른 범주 특성을 갖게 하는 한편, 데이터 처리 측면에서는 최신 그래프 처리 기술들에 쉽게 활용될 수 있도록 하기 위함이다.

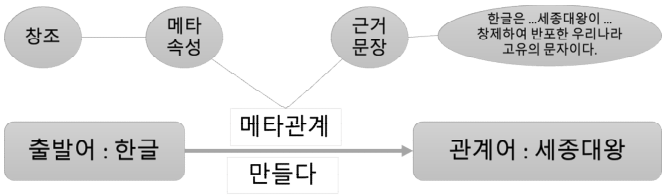


[그림 4] 한국언어문화 지식그래프 정보 구성

---

다른 나라 사람이 기대하는 답변이 다를 수 있다. 인공지능을 인간과 가깝게 인식할수록 이러한 답변은 객관적·중립적 사실이 아니라 주관적·공감적 사실에 기반해야 한다. 즉, 기준모델(Foundation LLM)에 내재된 지적 확률을 고정된 지식에 투영할 수 있게 한다. 그러므로 이러한 지식그래프는 해당 공동체의 축적된 공감하에 쌓아 올린 신뢰할 수 있는 자료, 즉 공적인 자료에 기반한 신중한 작업이 필요하다.

9) 여기서 '트리플'이란 두 개체 간의 관계 정보를 '주어 개체 - 관계 - 목적어 개체'와 같이 표현하는 구조를 이른다.

한국언어문화 지식그래프를 구성하는 정보는 출발어, 관계어, 메타관계 외에 메타관계에 의한 의미관계를 뒷받침하기 위해 메타속성과 근거문장(근거어휘)을 포함한다. 이러한 정보 구성은 이 논문이 지향하는 용어지식 플랫폼의 핵심 정보와 잘 대응된다.

<표 15> 한국언어문화 지식그래프와 용어지식 플랫폼 정보 유사성

| | 용어지식 플랫폼 | 지식 그래프 |
|---|---|---|
| 중심어 | 대상용어 | 출발어 |
| 범주 | 분류 | 메타속성 |
| 개념형성 | 관련어 | (메타)관계 및 관계어 |
| 근거 | 정의문/사용예시 | 근거문장 |

그러므로 용어지식 플랫폼의 용어 정보는 전문 분야의 개념에 대한 검색, 추론, 분류, 연관 등에 활용될 수 있는 확장적 지식표현을 제공하는 한편, 한국언어문화 지식그래프와 같이 정체성을 형성하는 폐쇄적 지식표현[10]을 통합할 수 있다.

### 3.3. 다국어 개념망과의 연계

여기서 한 걸음 더 나아가, 용어 개념도, 용어 사용 추이, 한국언어문화 지식그래프 등으로 표현된 용어지식을 세계적 다국어 개념망인 바벨넷(BabelNet) 등과의 연계를 통해 확장하는 방안도 고려할 수 있다.

바벨넷은 600개 언어, 약 2,300만 개의 항목으로 구성된 매우 큰 개념망으로, 용어의 개념과 개체를 연결하는 네트워크이다. 합성어 개념을 기반으로 하는 위드넷 모델을 따르지만, 다국어 어휘를 포함하여 확장한다.

10) 여기서 '폐쇄적 지식표현'은 온톨로지나 기존의 지식그래프가 지향하는 보편적, 근원적 사실로부터 확장되는 구체(具體, 인스턴스) 지식표현과 달리 특정 분야, 도메인, 정체성과 같이 개별적 특수성에서 지식그래프 데이터 특성이 보장되는 것을 의미한다. 이런한 논의는 온톨로지 연구와 함께 활발하게 전개되었는데 관련 논의는 한성국·이현실(2007) 등에서 확인할 수 있다.

각각 바벨넷의 연결 세트는 주어진 의미를 나타내며, 다양한 언어로 해당 의미를 표현하는 모든 동의어를 포함한다.

한국어와 한국언어문화 용어지식이 바벨넷의 600개 다국어 개념망과 연결되는 것이므로, 용어지식은 인공지능 통번역 자원으로 효용성을 가진다. 또한 LLM의 고질적인 환각현상을 줄이고 검색 성능 향상에도 기여할 것으로 생각된다.

## 4. 결론

용어지식의 통합과 확장은 고품질의 지식베이스 구축을 가능하게 하여, 인공지능의 학습 정확도를 높이고 언어 이해력을 향상시킨다. 이 연구는 국립국어원이 용어지식 플랫폼인 '온용어 플랫폼'을 구축하는 과정에서 고려했던, 인공지능 시대에 용어지식의 활용성을 극대화하기 위한 방안에 대해 논하였다.

기관별·분야별로 산재되어 있는 용어 데이터를 통합하는 방안으로 통일된 분류체계 적용과 일치어 연결을 제시하였다. 통일된 분류체계로는 「과학기술기본법」에 따라 체계적으로 관리되고, 5년마다 개정되어 최신 기술 동향을 반영할 수 있는 '과기표준 분류체계'를 채택하고, 이 분류체계에 따라 용어 데이터를 22개 대분류, 277개 중분류로 통합하였다. 또한 각기 다른 용어 자료에 있지만 형태와 개념이 같은 용어를 '일치어'로 명명하고, 용어 정보를 플랫폼상에서 한번에 볼 수 있도록 통합하는 방법론으로 일치어 연결을 제시하였다. 일치어 연결은 특정 용어가 각각의 용어 자료에서 어떻게 정의됐는지 볼 수 있고, 용어 자료의 특성에 따라 제공되는 부가적인 정보도 한번에 확인할 수 있다.

그리고 인공지능이 한국어와 한국문화를 학습하고 추론하는 자료로서의 활용성을 높이기 위해 용어지식을 확장하는 방법론을 제시하였다. 먼저 용어 정보를 입체적으로 제시하여 용어 의미 이해를 돕는 용어 개념

도를 고려하였는데, 용어가 가진 원어, 대역어, 정의문 추출 용어, 일치어, 동의어, 다듬은 말, 참고어 등의 의미 정보를 입체적으로 연결함으로써 언어학적 의미관계뿐만 아니라 분야별 사용역까지 추론 가능하게 하였다. 둘째, 용어 데이터에 공신력이 담보된 한국언론진흥재단의 '빅카인즈'의 사용 빈도를 연계하여, 용어 사용 추이 분석 방법을 고안하였다. 셋째, 한국형 인공지능 기술 개발 관점에서 한국언어문화 자료 공백을 해소할 수 있는 자료로 한국언어문화 지식그래프를 고안하였다. 한국언어문화 지식그래프의 표현은 최신 그래프 처리 기술들에 쉽게 활용될 수 있도록, 표제항인 중심어(출발어)와 관계어의 관계(메타관계)를 서술어로 삼아 그래프 표현 방식인 '트리플(triple)'로 구성하였다. 마지막으로 세계적 다국어 개념망인 바벨넷(BabelNet) 등과의 연계를 제안하여, 인공지능 통번역 자원으로서의 용어지식의 효용성을 제시하였다.

낱낱의 용어 데이터는 각 분야에서만 효용성을 지니는 반면, 지식으로 통합·확장된 용어지식은 본질적으로 인공지능의 환각현상을 줄이고 검색 성능 향상에도 기여할 것이다. 또한 번역기 개발 및 전문가용 특화 인공지능 개발 등 다양한 인공지능 기술 개발의 기초자료로 활용될 것이다.

## 참고문헌

강미영(2020), 「언어의 공공성과 공공 용어 관리」, 『우리말글』 87, 우리말글학회, 1~29쪽.

과학기술정보통신부, 한국과학기술기획평가원(2023), 「2023년 국가과학기술 표준분류체계 연구분야 해설서」.

구본관·박재연·이선웅·이진호·황선엽(2015), 『한국어 문법 총론 Ⅰ』, 집문당.

김민호(2022), 「운율구 경계 예측과 어의 중의성 해소를 위한 뉴로-심볼릭 모델 연구」, 부산대학교 박사학위논문.

김학래(2017), 『지식그래프』, 커뮤니케이션북스.

김학래(2021), 『온톨로지 과학자를 위한 지식그래프』, 한빛아카데미.

노영희·양정모·강지혜·김용환·이종욱·왕동호(2022), 「국내 분류체계와 학술표준분류체

계의 비교·분석 연구」, 『한국비블리아학회지』 33(2), 한국비블리아학회, 55~73쪽.
이상남·박창현·문지은(2023), 「2023 국가과학기술표준분류체계 개선방안 및 활용 기반 구축」, 한국과학기술기획평가원.
정희선·김희순·송현숙·이명희(2013), 「종교유적 건축물 정보의 메타데이터 구성과 온톨로지 구축」, 『한국도서관·정보학회지』, 44(1), 한국도서관·정보학회, 5~26쪽.
최호섭·임지희·배영준·최수일·옥철영(2006), 「온톨로지 구축 방법과 사례」, 『정보과학회지』, 24(4), 정보과학회, 31~44쪽.
한성국·이현실(2007), 「응용프로파일 코어 온톨로지 설계 및 구현」, 『정보관리학회지』 24(3), 정보관리학회, 245~269쪽.
Pan, S., Luo, L., Wang, Y., Chen, C., Wang, J., & Wu, X.(2023), Unifying large language models and knowledge graphs: A roadmap, *arXiv preprint arXiv:2306.08302*.

◘ 이현주
❀ 소　　속: 국립국어원 언어정보과
❀ 주　　소: [07511] 서울 강서구 금낭화로 154
❀ 전자우편: lhj980028@korea.kr

◘ 위진
❀ 소　　속: 국립국어원 언어정보과
❀ 주　　소: [07511] 서울 강서구 금낭화로 154
❀ 전자우편: wj0119@korea.kr

◘ 강미영
❀ 소　　속: 국립국어원 언어정보과
❀ 주　　소: [07511] 서울 강서구 금낭화로 154
❀ 전자우편: mykang@korea.kr

◘ 곽용진
❀ 소　　속: ㈜이르테크
❀ 주　　소: [07511] 대전시 유성구 계룡로 114
❀ 전자우편: silhuett@iirtech.co.kr

◎ 논문접수: 2024년 11월 25일
◎ 논문심사: 2024년 12월 16일
◎ 게재결정: 2024년 12월 19일

<Abstract>

# Integration and Expansion Methods of Terminology Knowledge

## - Focused on the National Institute of the Korean Language's Ongoing Terminology Platform -

Lee, Hyun-ju · Wee, Jin · Kang, Mi-young · Kwak, Yong-Jin

(National Institute of the Korean Language NIKL) · (NIKL) · (NIKL) · (IIR TECH)

This study presents a method for designing and utilizing a terminology knowledge platform that can contribute to the advancement of Korean AI technology by integrating and systematizing all the terminology knowledge built and utilized by various government agencies and organizations in the country. The study proposes a methodology for integrating databases of terminologies, such as glossaries, scattered across different agencies or fields into a unified system by applying a standardized classification system.

It also discusses the process of linking terms with the same meaning and concept but presented in different forms across various glossaries, along with the associated issues and empirical solutions. Furthermore, the study explores ways to expand the terminology data into knowledge by adding semantic relationships and rules, and analyzes social phenomena by examining the statistical trends in terminology changes, thereby enhancing the usability of terminology knowledge.

Furthermore, this study explores ways to address hallucination phenomena related to Korean language and culture in artificial intelligence through the construction of knowledge graphs. It also seeks development directions that can connect this effort with global knowledge networks.

Keywords: Terminology Knowledge, Glossary, Knowledge Graph, Domain Classification, Artificial Intelligence, Korean Language and Culture, Hallucination Phenomena